

Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI) TIP7077 – Inteligência Computacional Aplicada

Paulo Abner Aurelio Mesquita - 603570

2026.1

Introdução

O presente relatório apresenta os resultados referentes ao 1º Trabalho Computacional da disciplina, cujo objetivo central é a implementação e a avaliação de três abordagens distintas de regressão aplicadas a um mesmo conjunto de dados experimental (*Gauss3*):

1. Modelo Polinomial de ordem k ;
2. Modelo de Regressão Linear por Partes;
3. Modelo de Inferência Fuzzy do tipo Mamdani.

Para cada modelo, procedeu-se à busca iterativa pela estrutura ótima com base na maximização do coeficiente (R^2). Adicionalmente, a metodologia de avaliação incluiu a análise gráfica do histograma dos resíduos (verificando a hipótese de gaussianidade), o gráfico de dispersão entre os valores medidos e preditos, e a verificação da relação matemática entre o coeficiente de correlação linear e o índice R^2 .

Implementação Computacional

A implementação dos algoritmos foi realizada inteiramente na linguagem Python, sem a utilização de bibliotecas de aprendizado de máquina de alto nível (como o *scikit-learn*), priorizando a manipulação direta de matrizes e vetores via NumPy. A estrutura do código foi organizada de forma modular:

- **abner_math.py**: Script contendo as funções matemáticas fundamentais comuns aos modelos, tais como o cálculo da soma dos erros quadráticos, erro quadrático médio, o coeficiente (R^2) e a classe **Gauss** para a manipulação dos dados.

- **dataset.py**: Módulo responsável pela leitura, limpeza e carregamento do conjunto de dados *Gauss3.dat*.

A modelagem de cada abordagem foi isolada em um script executável específico:

- `modelo_polinomial_de_ordem_k.py`
- `modelo_regressao_por_partes.py`
- `modelo_fuzzy_otimizado.py`

1 Modelo 1: Regressão Polinomial de Ordem k

A primeira abordagem avaliada consistiu em ajustar um modelo de regressão polinomial global aos dados. O algoritmo implementado realizou uma busca iterativa, incrementando o grau do polinômio a partir de $k = 0$ até um limite máximo estabelecido ($k = 20$), com o objetivo de maximizar o coeficiente de determinação (R^2). O algoritmo incluiu um critério de parada caso houvesse queda no desempenho.

Execução

Abaixo segue a execução e saída do script *modelo_polinomial_de_ordem_k.py*

```
python .\modelo_polinomial_de_ordem_k.py
Carregadas 250 observações.
Iniciando busca iterativa por melhor grau...
Grau 0: R² = 0.000000
Grau 1: R² = 0.352936
Grau 2: R² = 0.578111
Grau 3: R² = 0.580130
Grau 4: R² = 0.850255
Grau 5: R² = 0.850403
Grau 6: R² = 0.957442
Grau 7: R² = 0.957624
Grau 8: R² = 0.978821
Grau 9: R² = 0.979246
Grau 10: R² = 0.979833

Melhor ajuste encontrado no Grau 10 (R²: 0.979833)
Beta final: [ 1.03296252e+02 -6.81312865e+02  8.93980770e+03 -5.73308679e+04
 4.06537395e+04  9.59258249e+05 -4.16932566e+06  7.85900078e+06
-7.79169987e+06  3.97855549e+06 -8.27469715e+05]
```




Figure 1: Evolução do Ajuste Polinomial no Dataset Gauss3

Parte A:

Após a execução do algoritmo de busca, a melhor estrutura encontrada para o conjunto de dados *Gauss3* foi o polinômio de **ordem $k = 10$** .

Para essa estrutura ótima, o modelo alcançou um **Coefficiente de Determinação (R^2) de 0.979833**. Esse valor indica que o modelo polinomial conseguiu explicar aproximadamente 97.9% da variância dos dados.

A Figura 1 apresenta a evolução da curva do modelo polinomial de ordem k , sendo incrementado de 1 a 10.

Parte B:

B.1) Histograma dos Resíduos

A Figura 2 apresenta o histograma dos erros de predição (resíduos) sobreposto à curva de densidade de probabilidade de uma Gaussiana.

Análise quanto à gaussianidade: Analisando o histograma obtido, nota-se que os resíduos estão, em sua maioria, concentrados em torno de zero, o que é desejável. Observa-se, também, que o histograma apresenta formato de sino que mostra a boa distribuição.

B.2) Gráfico de Dispersão

A Figura 3 ilustra o comportamento dos valores preditos pelo modelo em relação aos valores reais medidos. A linha tracejada diagonal representa o ajuste ideal (onde Medido = Predito).

Análise do Ajuste: Este gráfico está de acordo com o esperado para um bom ajuste, visto que os pontos (em laranja) formam uma nuvem relativamente




Figure 2: Histograma dos resíduos para o modelo polinomial ótimo.

estreita acompanhando a linha diagonal ideal. No entanto, percebe-se um espalhamento maior nos valores mais altos de Y .

B.3) Coeficiente de Correlação

Calculou-se o coeficiente de correlação linear (r) entre os valores de saída medidos (y) e os valores preditos ($\hat{y}$), obtendo-se o valor de $r = \mathbf{0.989865}$.

Elevando-se este valor ao quadrado, temos $r^2 = (0.989865)^2 \approx \mathbf{0.979833}$. Conforme a teoria estatística, este valor quadrático da correlação é exatamente igual ao Coeficiente de Determinação (R^2) obtido na avaliação global da Parte A.

2 Modelo 2: Regressão Linear por Partes

A segunda abordagem avaliada consistiu em um modelo de regressão linear por partes. O algoritmo implementado dividiu o domínio da variável de entrada X em subintervalos iguais e ajustou uma reta local para cada partição. Realizou-se uma busca iterativa, variando o número de partições de 1 a 20, com o objetivo de encontrar a estrutura que maximizasse o coeficiente de determinação (R^2).

Execução

Abaixo segue a saída do script *modelo_regressao_por_partes.py* no terminal:

```
python .\modelo_regressao_por_partes.py
Carregadas 250 observações.
R² para 1 partições: 0.352936
```




Figure 3: Gráfico de dispersão entre a saída medida e a saída predita (Modelo Polinomial).

R^2 para 2 partições: 0.723766
 R^2 para 3 partições: 0.891090
 R^2 para 4 partições: 0.966985
 R^2 para 5 partições: 0.967045
 R^2 para 6 partições: 0.973301
 R^2 para 7 partições: 0.993585
 R^2 para 8 partições: 0.986964
 R^2 para 9 partições: 0.993636
 R^2 para 10 partições: 0.993234
 R^2 para 11 partições: 0.994922
 R^2 para 12 partições: 0.995602
 R^2 para 13 partições: 0.995772
 R^2 para 14 partições: 0.995985
 R^2 para 15 partições: 0.996523
 R^2 para 16 partições: 0.996555
 R^2 para 17 partições: 0.996559
 R^2 para 18 partições: 0.996956
 R^2 para 19 partições: 0.997097
 R^2 para 20 partições: 0.996740

Parte A:

Após a execução do algoritmo de busca, a melhor estrutura encontrada para o conjunto de dados *Gauss3* utilizou **19 partições**. A partir de 20 partições, observou-se uma leve degradação no desempenho.

Para essa estrutura ótima, o modelo alcançou um **Coefficiente de Determinação (R^2) de 0.997097**. Esse valor indica um ajuste excepcionalmente bom, superior ao modelo polinomial.

A Figura 4 apresenta o ajuste final do modelo sobre os dados reais utilizando as 19 partições.

Parte B:

B.1) Histograma dos Resíduos

A Figura 5 apresenta o histograma dos erros de predição (resíduos) para o modelo particionado, sobreposto à curva normal teórica.

Análise quanto à gaussianidade: O alto valor de R^2 alcançado reflete que os resíduos estão fortemente concentrados em torno de zero. O comportamento geral se assemelha a uma distribuição gaussiana de variância muito baixa como pode ser observado na Figura 5.

B.2) Gráfico de Dispersão

A Figura 6 ilustra o comportamento dos valores preditos pelo modelo em relação aos valores reais medidos.




Figure 4: Ajuste do Modelo de Regressão Linear por Partes (19 partições) no Dataset Gauss3.

Análise do Ajuste: O gráfico comprova o excelente desempenho do modelo. Os pontos estão quase perfeitamente alinhados sobre a linha tracejada diagonal de inclinação de 45 graus, indicando que, em toda a faixa de valores (dos vales aos picos de Y), o modelo conseguiu prever a saída com alto grau de precisão.

B.3) Coeficiente de Correlação

Calculou-se o coeficiente de correlação linear (r) entre os valores de saída medidos (y) e os valores preditos ($\hat{y}$), obtendo-se o valor de $r = \mathbf{0.998547}$.

Elevando-se este valor ao quadrado, obtém-se $r^2 = (0.998547)^2 \approx \mathbf{0.997097}$. Conforme esperado estatisticamente, este valor quadrático espelha com exatidão o Coeficiente de Determinação (R^2) de 0.997097 destacado na Parte A.

3 Modelo 3: Modelo Fuzzy do tipo Mamdani

A terceira e última abordagem avaliada consistiu em um Modelo Fuzzy do tipo Mamdani. O modelo utilizou funções de pertinência gaussianas para particionar o espaço da variável de entrada e consequentes do tipo *singleton* (valores numéricos fixos) para a saída. A defuzzificação foi realizada pelo método da média ponderada (Centro de Gravidade). O algoritmo buscou iterativamente o número ótimo de regras (funções de pertinência, N_{mf}), variando de 2 até 20.




Figure 5: Histograma dos resíduos para o modelo de regressão por partes ótimo.

Execução

Abaixo segue a saída do script *modelo_fuzzy_otimizado.py* no terminal:

```
python .\modelo_fuzzy_otimizado.py
Carregadas 250 observações.
Nmf: 2 | R²: 0.223056
Nmf: 3 | R²: 0.254682
Nmf: 4 | R²: 0.329005
Nmf: 5 | R²: 0.690498
Nmf: 6 | R²: 0.754270
Nmf: 7 | R²: 0.783423
Nmf: 8 | R²: 0.914936
Nmf: 9 | R²: 0.887981
Nmf: 10 | R²: 0.943894
Nmf: 11 | R²: 0.937574
Nmf: 12 | R²: 0.956248
Nmf: 13 | R²: 0.964619
Nmf: 14 | R²: 0.971847
Nmf: 15 | R²: 0.976839
Nmf: 16 | R²: 0.981754
Nmf: 17 | R²: 0.981988
Nmf: 18 | R²: 0.984104
Nmf: 19 | R²: 0.987043
Nmf: 20 | R²: 0.989124
```

Melhor modelo encontrado com Nmf=20 (R²: 0.989124)




Figure 6: Gráfico de dispersão entre a saída medida e a saída predita (Regressão por Partes).

Parte A:

Após a execução da busca iterativa, a melhor estrutura encontrada para o conjunto de dados *Gauss3* foi o modelo com $N_{mf} = 20$ **subconjuntos fuzzy (regras)**.

Para essa estrutura, o modelo alcançou um **Coefficiente de Determinação (R^2) de 0.989124**. O uso das funções gaussianas conferiu ao modelo uma curva de aproximação bastante suave e estável, mapeando adequadamente a não linearidade dos dados sem a instabilidade numérica apresentada pelo modelo polinomial de ordem alta.

A Figura 7 apresenta a curva de predição do modelo Fuzzy sobre os dados reais, juntamente com a marcação dos centros de cada regra.




Figure 7: Ajuste do Modelo Fuzzy Mamdani ($N_{mf} = 20$) no Dataset Gauss3.

Valores dos Singletons (Consequentes das Regras)

Conforme exigido pelas especificações do trabalho, os valores numéricos exatos extraídos para a saída de cada uma das 20 regras (os *singletons*) da estrutura ótima estão listados abaixo:

- Regra 1: 97.587760
- Regra 2: 85.086655
- Regra 3: 73.271778
- Regra 4: 60.834615
- Regra 5: 56.172066
- Regra 6: 50.420203
- Regra 7: 55.026329
- Regra 8: 88.989725
- Regra 9: 125.643426
- Regra 10: 128.290605
- Regra 11: 108.924137
- Regra 12: 105.149642

- Regra 13: 74.323315
- Regra 14: 34.035597
- Regra 15: 14.460935
- Regra 16: 10.380652
- Regra 17: 10.311787
- Regra 18: 9.549169
- Regra 19: 9.717049
- Regra 20: 4.875312

Parte B:

B.1) Histograma dos Resíduos

A Figura 8 apresenta o histograma dos erros de predição do modelo Fuzzy, comparado a uma curva gaussiana de mesma média e desvio padrão.




Figure 8: Histograma dos resíduos para o modelo Fuzzy Mamdani ótimo.

Análise quanto à gaussianidade: O histograma apresenta uma concentração de resíduos muito próxima de zero e distribuída quase simetricamente perfeita em forma de sino, aderindo satisfatoriamente ao comportamento esperado de uma distribuição normal.




Figure 9: Gráfico de dispersão entre a saída medida e a saída predita (Modelo Fuzzy Mamdani).

B.2) Gráfico de Dispersão

A Figura 9 ilustra a dispersão entre a saída medida (Y real) e a saída inferida pelo sistema Fuzzy.

Análise do Ajuste: A dispersão mostra uma alta correlação, com os pontos acompanhando fielmente a reta de referência ideal de 45 graus. Apesar de apresentar um espalhamento sutilmente maior nos picos da função se comparado ao modelo linear por partes, o ajuste Fuzzy se mostra visualmente excelente e extremamente robusto, lidando bem com toda a faixa de valores do *dataset*.

B.3) Coeficiente de Correlação

Calculou-se o coeficiente de correlação linear de Pearson (r) entre os valores de saída medidos (y) e os preditos ($\hat{y}$), resultando em $r = \mathbf{0.994547}$.

Elevando-se o coeficiente de Pearson ao quadrado, obtém-se $r^2 = (0.994547)^2 \approx \mathbf{0.989124}$. Esta operação estatística confirma matematicamente que a variância explicada, capturada pelo coeficiente de correlação, equivale exatamente ao Coeficiente de Determinação (R^2) de 0.989124 reportado na Parte A do modelo.

Conclusão

A análise comparativa dos resultados permite destacar as seguintes considerações sobre cada abordagem:

- **Modelo Polinomial (Ordem $k = 10$, $R^2 \approx 0.979$):** Embora tenha alcançado um bom coeficiente de determinação, esta abordagem paramétrica apresentou limitações. A necessidade de elevar o grau do polinômio para capturar as variações locais resultou em coeficientes (β) de magnitudes extremamente altas.
- **Regressão Linear por Partes (19 partições, $R^2 \approx 0.997$):** Foi o modelo que apresentou o maior R^2 numérico. Porém, apresenta uma descontinuidade matemática (ou quebra de suavidade) nas fronteiras de cada partição, resultando em uma curva fragmentada.
- **Modelo Fuzzy Mamdani ($N_{mf} = 20$, $R^2 \approx 0.989$):** Esta abordagem demonstrou ser a melhor relação entre precisão e qualidade geométrica. O uso de funções de pertinência gaussianas garantiu que a superfície de resposta do modelo fosse matematicamente suave e contínua em todo o domínio. O modelo manteve estabilidade estrutural sem os problemas de magnitude dos coeficientes vistos na abordagem polinomial.

Conclui-se, portanto, que para conjuntos de dados com características semelhantes ao *Gauss3*, abordagens como a Regressão por Partes e o Modelo Fuzzy são superiores às aproximações polinomiais clássicas. Dentre os três, o modelo Fuzzy Mamdani destacou-se por fornecer uma alta variância ($> 98\%$), aliada à suavidade contínua de sua curva preditiva.